

OSS "개발자"의 Machine Learning 분투기

머신러닝 시작부터 예측모델 배포까지

한국마이크로소프트 | 김대우

2016-11-18

SOSCON SAMSUNG
OPEN SOURCE
CONFERENCE



OSS "개발자"의 Machine Learning 분투기

개발자와 머신러닝(?)

어디에 어떻게 사용해야 하나

머신러닝 데모

학습모델 / 예측모델

지도 학습 / 비지도 학습 / 분석 알고리즘

예측모델 생성 데모

예측 모델을 API로 노출 및 Python 등에서 사용

01

02

03

04

05

06

07



개발자 & 머신러닝

“

뭐... 원데 그게?

”

deep dive: handling of time

extend our example to an RNN

$$h_1(t) = \sigma(W_1 x(t) + H_1 h_1(t-1) + b_1)$$

$$h_2(t) = \sigma(W_2 h_1(t) + H_2 h_2(t-1) + b_2)$$

$$P(t) = \text{softmax}(W_{\text{out}} h_2(t) + b_{\text{out}})$$

$$ce(t) = L^T(t) \log P(t)$$

$$\sum_{\text{corpus}} ce(t) = \max$$

$$h1 = \text{Sigmoid}(w1 * x + H1 * \text{PastValue}(h1) + b1)$$

$$h2 = \text{Sigmoid}(w2 * h1 + H2 * \text{PastValue}(h2) + b2)$$

$$P = \text{Softmax}(w_{\text{out}} * h2 + b_{\text{out}})$$


$$ce = \text{CrossEntropy}(L, P)$$

→ no explicit notion of time

deep dive: 1-bit SGD

- quantize **gradients** to but **1 bit per value** with **error feedback**
 - carries over quantization error to next minibatch

$$\begin{aligned}G_{ij\ell}^{\text{quant}}(t) &= \mathcal{Q}(G_{ij\ell}(t) + \Delta_{ij\ell}(t - N)) \\ \Delta_{ij\ell}(t) &= G_{ij\ell}(t) - \mathcal{Q}^{-1}(G_{ij\ell}^{\text{quant}}(t))\end{aligned}$$



1-Bit Stochastic Gradient Descent and its Application to Data-Parallel Distributed Training of Speech DNNs, InterSpeech 2014, F. Seide, H. Fu, J. Droppo, G. Li, D. Yu

“

OK.
잠시 방황한거 뿐이야.

”

매니저

산채로 잡아라

“

어느 교수님 말씀 :

단지, 우리와 단어가 다를 뿐이야

”

“

R, SAS, Python?

”

“

Machine Learning & Cloud(?)

”

“

ML로 태어나 Cloud에서 산다

”

어디에 어떻게 사용해야 하나

머신러닝 데모

학습모델 / 예측모델

“

바보(머신)에게 공부할 기회를
= 학습모델

”

“

바보(머신)에게 배운거 물어볼까
= 예측모델

”

지도 학습

비지도 학습

구분	Reinforcement Learning	Machine Learning (Supervised Learning)	비고
목적함수	보상을 최대화 (또는 손실을 최소화)	오차를 최소화 (오차 = 추정 - 실제)	
산출방식	순차적으로 현재 스테이지의 보상과 총 보상을 산출하여 "총 보상"이 최대화 되도록 함	실제 사례를 기반으로 사례와 가장 유사하게 모사하도록 함수를 구성하도록 함	
산출 방법론	Optimization	분류문제와 예측문제로 구분되며 다양한 알고리즘 존재	
데이터 구성	State 별 Action Matrix (모든 가능한 State 각각에 대한 모든 실행 가능한 Action과 확률)	State vs. Action에 대한 성공과 실패 사례	
특징	규칙기반으로의 설계가 용이함 (Heuristic 설계 용이)	- 데이터마이닝: 규칙(if/else) 기반 설계 용이 - 기계학습: 규칙 파악이 어려움	기계학습은 정확도 향상이 주 목표임
구현 방법	최적화 엔진 (Dynamic LP 등)	통계 소프트웨어 또는 기계학습 엔진	

Unsupervised Learning


Supervised Learning

학습대상이 있는지(Target의 여부)에 따라

→ Unsupervised Learning(自律학습)과 Supervised Learning(指導학습)으로 구분

Unsupervised Learning

Unsupervised learning(자율학습)



Clustering

- Hierarchical Clustering
- K-Means
- Mixture Modeling

Supervised Learning

Supervised learning(지도학습)



Target

Continuous

- Decision Tree
- Boosting Trees
- Random Forest
- SVM(Support Vector Machine)
- Neural Networks

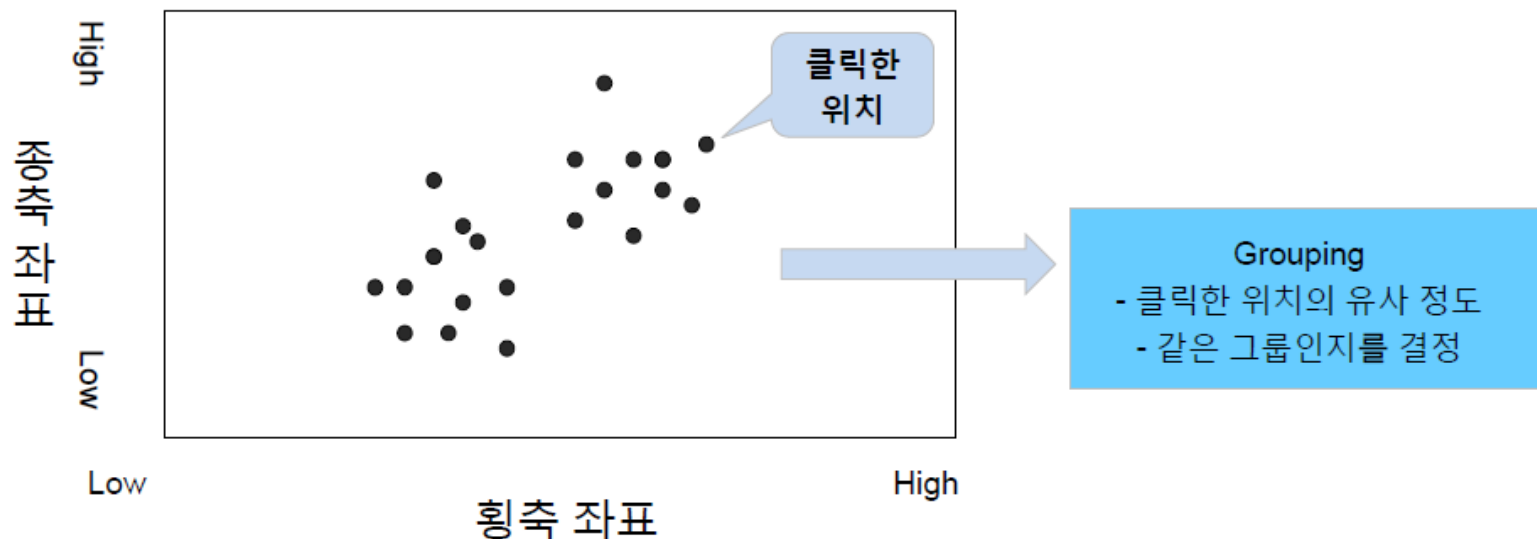
Discrete

- Naïve Bayes
- K-Nearest Neighbors
- Logistic Regression
- SVM

다양한 분석 알고리즘

Clustering

어떤 사용자가 화면에 클릭한 위치들의 집합을 찾기 위해 **Grouping**을 한다고 하면
여기서, 각 점은 클릭한 위치를 의미



클릭한 포인트 간의
비유사도(거리)로
표현 가능) 정의

$$\text{Distance} = \sqrt{(X_2 - X_1)^2 + (Y_2 - Y_1)^2}$$

$$d_{ij} = d(X_i, X_j) = \left[\sum_{k=1}^p |X_{ik} - X_{jk}|^m \right]^{1/m}$$

$$d_{ij} = d(X_i, X_j) = \left[\sum_{k=1}^p \left| \frac{X_{ik} - X_{jk}}{S_k} \right|^m \right]^{1/m}$$

군집분석 알고리즘

- **Hierarchical Cluster Procedures**

- Single Linkage Method
- Complete Linkage Method
- Average Linkage Method
- Ward's Method
- Centroid Method



- **Nonhierarchical Cluster Procedures**

- K-means Clustering

- Agglomerative: '가까운' 객체끼리 군집화 시키는 방법
- Divisive: '먼' 객체들을 나누어 가는 방법
- 군집의 병합 또는 분리되는 과정을 이차원도면의 Dendrogram를 사용하여 간략히 표현
- 군집화 과정에서 어떤 개체가 일단 다른 군집에 속하면 다시는 다른 군집에 속하지 못함
- 개체의 수가 적을 때 유용

예측모델 생성 데모

API로 노출

Python 등에서 API 사용

Q & A

OSS "개발자"의 Machine Learning 분투기

머신러닝 시작부터 예측모델 배포까지

한국마이크로소프트 | 김대우

2016-11-18

SOSCON SAMSUNG
OPEN SOURCE
CONFERENCE

